

Informe: Análisis TF-IDF y similitud coseno

Informe: Análisis TF-IDF y similitud coseno

Fecha: 2025-11-04

Resumen

Este informe resume el análisis realizado con la aplicación CLI `tfidf`` (C++) incluida en este repositorio. El software procesa documentos `.txt``, aplica filtrado por stopwords y lematización, y calcula TF, IDF, TF-IDF y la matriz de similitud coseno entre documentos.

Alcance y limitaciones

- El repositorio solicitado en <https://github.com/ull-cs/gestion-conocimiento/tree/main/recommender-systems/examples-documents> no pudo ser descargado automáticamente desde este entorno (restricciones de red). Para reproducir exactamente esos documentos, por favor provee los ficheros o descarga y colócalos en el workspace (por ejemplo en `ejemplos/`` o `samples/``).
- En su lugar, se ha utilizado el conjunto de ejemplo local (`samples/doc1.txt``, `samples/doc2.txt``) y un conjunto nuevo de 10 documentos creados en `samples/new_docs/`` (ver más abajo).

Metodología

- Tokenización: se normalizan los caracteres a minúsculas y se separan tokens por caracteres no alfabéticos/digitales.
- Stopwords: se eliminan tokens presentes en `samples/stopwords.txt``.
- Lematización: se sustituye cada token por su lema según `samples/lemmas.txt``.
- TF: recuento bruto de ocurrencias por documento.
- IDF: $\log(N / df)$ con N = número de documentos, df = número de documentos con el término.
- TF-IDF: $TF * IDF$.
- Similitud coseno: producto escalar de vectores TF-IDF normalizado por normas.

Datos analizados

- Documentos locales de ejemplo:
 - `samples/doc1.txt``
 - `samples/doc2.txt``
- Conjunto propuesto (10 nuevos documentos creados aquí):
 - `samples/new_docs/doc01.txt`` — sobre un gato en la alfombra
 - `samples/new_docs/doc02.txt`` — economía local y negocios
 - `samples/new_docs/doc03.txt`` — lluvia y flores
 - `samples/new_docs/doc04.txt`` — partido de fútbol y gol
 - `samples/new_docs/doc05.txt`` — receta de sopa de verduras
 - `samples/new_docs/doc06.txt`` — innovaciones tecnológicas, IA
 - `samples/new_docs/doc07.txt`` — viaje por carretera y paisaje
 - `samples/new_docs/doc08.txt`` — concierto de música
 - `samples/new_docs/doc09.txt`` — salud pública y programas
 - `samples/new_docs/doc10.txt`` — mercado de arte local

Resultados — documentos de ejemplo (`samples/doc1.txt``, `samples/doc2.txt``)

Los resultados para los documentos de ejemplo locales se almacenan en `outputs/doc_examples.txt`` y se muestran a continuación (extracto):

```
...
$(cat outputs/doc_examples.txt)
```

Resultados — 10 documentos propuestos

Los resultados completos (TF/IDF/TF-IDF y matriz de similitud) para los 10 documentos nuevos están en `outputs/new_docs.txt``. Se incluye a continuación el contenido:

```
...
$(cat outputs/new_docs.txt)
```

Análisis y conclusiones

- Observaciones sobre TF/IDF:
 - En documentos pequeños y con vocabulario distinto por tema (arte, cocina, tecnología), muchos términos aparecen en un único documento -> IDF alto, TF-IDF alto para esos términos.
 - Términos muy comunes (artículos y conjunciones) reciben IDF cercano a 0 o son filtrados por stopwords, por lo que su TF-IDF es bajo o nulo.
- Observaciones sobre similitud coseno:
 - En el conjunto `new_docs` se observan similitudes bajas en general (valores ~0.00x-0.15), salvo casos donde hay vocabulario compartido (por ejemplo, textos sobre ocio/turismo pueden mostrar similitud más alta entre sí).
 - Valores mayores indican documentos con términos únicos pero relacionados (por ejemplo, `doc04` partido de fútbol muestra una similitud mayor con `doc08` concierto? — revisar matriz para confirmar temas relacionados por términos como "el", "la" y palabras no descartadas).
- Limitaciones:
 - Tokenización y lematización son simples y pueden fragmentar palabras (p. ej. truncados si hay acentos o caracteres especiales); mejorar normalización Unicode y lematización aumentaría calidad.
 - El IDF usado es $\log(N/df)$ sin suavizado; en corpus muy pequeño produce valores extremos.

Propuesta de 10 documentos adicionales (descripciones)

Listado (ya creados en `samples/new_docs/`):

1. doc01.txt — El gato negro duerme en la alfombra...
2. doc02.txt — Economía local, negocios pequeños...
3. doc03.txt — Lluvia y flores en el jardín...
4. doc04.txt — Partido de fútbol y gol de último minuto...
5. doc05.txt — Receta de sopa de verduras...
6. doc06.txt — Innovaciones tecnológicas e IA...
7. doc07.txt — Viaje por carretera y paisajes...
8. doc08.txt — Concierto de música clásica y contemporánea...
9. doc09.txt — Salud pública y programas comunitarios...
10. doc10.txt — Mercado de arte local; pinturas y esculturas...

Cómo reproducir (comandos)

Compilar con Makefile (genera `bin/tfidf`):

```
```bash
make
```
```

Ejecutar sobre los 10 documentos nuevos:

```
```bash
./bin/tfidf -d samples/new_docs -s samples/stopwords.txt -l samples/lemmas.txt >
outputs/new_docs.txt
```
```

Exportar los resultados en PDF: este repositorio incluye `report.md` y `report.pdf` si la conversión fue exitosa.

Siguientes pasos recomendados

- Normalizar Unicode y acentos (por ejemplo con ICU o una librería de normalización)
- Añadir opción para normalizar TF (TF normalizado o log-scaling)
- Añadir salida CSV/TSV/JSON para facilitar análisis posterior
- Integrar scripts para crear automáticamente un resumen de top-k términos por documento

Apéndice: archivos de salida generados

- `outputs/doc_examples.txt` — salida para ejemplos locales
- `outputs/new_docs.txt` — salida para 10 documentos propuestos

Fin del informe.

Apéndice: Salida de la aplicación (ejemplos locales)

Documento: /workspaces/modelos_basados_contenido/samples/doc1.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|---------|----|-----|--------|
|-----|---------|----|-----|--------|

Documento: /workspaces/modelos_basados_contenido/samples/doc2.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|---------|----|-----|--------|
|-----|---------|----|-----|--------|

Matriz de similitud coseno:

| | | |
|---|---|---|
| | 0 | 1 |
| 0 | 0 | 0 |
| 1 | 0 | 0 |

Apéndice: Salida de la aplicación (10 documentos nuevos)

Documento: /workspaces/modelos_basados_contenido/samples/new_docs/doc01.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|----------|----|----------|----------|
| 5 | al | 1 | 2.30259 | 2.30259 |
| 6 | alfombra | 1 | 2.30259 | 2.30259 |
| 38 | duerme | 1 | 2.30259 | 2.30259 |
| 40 | el | 1 | 0.356675 | 0.356675 |
| 41 | en | 2 | 1.60944 | 3.21888 |
| 49 | gata | 1 | 2.30259 | 2.30259 |
| 50 | gato | 2 | 2.30259 | 4.60517 |
| 58 | la | 3 | 0.356675 | 1.07002 |
| 66 | maulla | 1 | 2.30259 | 2.30259 |
| 70 | mira | 1 | 2.30259 | 2.30259 |
| 78 | negro | 1 | 2.30259 | 2.30259 |
| 79 | noche | 1 | 2.30259 | 2.30259 |
| 121 | y | 1 | 0.105361 | 0.105361 |

Documento: /workspaces/modelos_basados_contenido/samples/new_docs/doc02.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|------------|----|----------|----------|
| 0 | a | 1 | 2.30259 | 2.30259 |
| 15 | buscan | 1 | 2.30259 | 2.30259 |
| 22 | clientes | 1 | 2.30259 | 2.30259 |
| 30 | crece | 1 | 2.30259 | 2.30259 |
| 39 | econom | 1 | 2.30259 | 2.30259 |
| 58 | la | 1 | 0.356675 | 0.356675 |
| 60 | lentamente | 1 | 2.30259 | 2.30259 |
| 62 | local | 1 | 1.20397 | 1.20397 |
| 63 | los | 1 | 0.916291 | 0.916291 |
| 67 | mejoran | 1 | 2.30259 | 2.30259 |
| 77 | negocios | 1 | 2.30259 | 2.30259 |
| 82 | os | 1 | 1.60944 | 1.60944 |
| 92 | peque | 1 | 2.30259 | 2.30259 |
| 105 | servicio | 1 | 2.30259 | 2.30259 |
| 110 | su | 1 | 2.30259 | 2.30259 |
| 121 | y | 1 | 0.105361 | 0.105361 |

Documento: /workspaces/modelos_basados_contenido/samples/new_docs/doc03.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|-----------|----|----------|----------|
| 4 | agua | 1 | 2.30259 | 2.30259 |
| 16 | ca | 1 | 2.30259 | 2.30259 |
| 31 | crecer | 1 | 2.30259 | 2.30259 |
| 32 | da | 1 | 2.30259 | 2.30259 |
| 34 | del | 1 | 1.60944 | 1.60944 |
| 47 | flores | 2 | 2.30259 | 4.60517 |
| 57 | jard | 1 | 2.30259 | 2.30259 |
| 58 | la | 1 | 0.356675 | 0.356675 |
| 59 | las | 2 | 1.60944 | 3.21888 |
| 61 | lluvia | 1 | 2.30259 | 2.30259 |
| 74 | n | 1 | 1.20397 | 1.20397 |
| 76 | necesitan | 1 | 2.30259 | 2.30259 |
| 88 | para | 1 | 2.30259 | 2.30259 |
| 101 | reg | 1 | 2.30259 | 2.30259 |
| 108 | sol | 1 | 2.30259 | 2.30259 |

121 y 1 0.105361 0.105361

Documento: /workspaces/modelos_basados_contenido/samples/new_docs/doc04.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|-------------|----|----------|----------|
| 3 | aficionados | 1 | 2.30259 | 2.30259 |
| 20 | celebraron | 1 | 2.30259 | 2.30259 |
| 27 | con | 1 | 1.60944 | 1.60944 |
| 33 | de | 1 | 1.20397 | 1.20397 |
| 40 | el | 2 | 0.356675 | 0.71335 |
| 41 | en | 2 | 1.60944 | 3.21888 |
| 45 | f | 1 | 1.60944 | 1.60944 |
| 52 | gol | 1 | 2.30259 | 2.30259 |
| 58 | la | 1 | 0.356675 | 0.356675 |
| 63 | los | 1 | 0.916291 | 0.916291 |
| 64 | ltimo | 1 | 2.30259 | 2.30259 |
| 69 | minuto | 1 | 2.30259 | 2.30259 |
| 89 | partido | 1 | 2.30259 | 2.30259 |
| 94 | plaza | 1 | 2.30259 | 2.30259 |
| 112 | tbol | 1 | 2.30259 | 2.30259 |
| 114 | termin | 1 | 2.30259 | 2.30259 |
| 117 | un | 1 | 2.30259 | 2.30259 |

Documento: /workspaces/modelos_basados_contenido/samples/new_docs/doc05.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|-----------|----|----------|----------|
| 7 | apio | 1 | 2.30259 | 2.30259 |
| 19 | cebolla | 1 | 2.30259 | 2.30259 |
| 24 | cocinar | 1 | 2.30259 | 2.30259 |
| 33 | de | 1 | 1.20397 | 1.20397 |
| 53 | incluye | 1 | 2.30259 | 2.30259 |
| 58 | la | 1 | 0.356675 | 0.356675 |
| 85 | paciencia | 1 | 2.30259 | 2.30259 |
| 91 | patata | 1 | 2.30259 | 2.30259 |
| 100 | receta | 1 | 2.30259 | 2.30259 |
| 102 | requiere | 1 | 2.30259 | 2.30259 |
| 109 | sopa | 1 | 2.30259 | 2.30259 |
| 118 | una | 1 | 2.30259 | 2.30259 |
| 119 | verduras | 1 | 2.30259 | 2.30259 |
| 121 | y | 1 | 0.105361 | 0.105361 |
| 122 | zanahoria | 1 | 2.30259 | 2.30259 |

Documento: /workspaces/modelos_basados_contenido/samples/new_docs/doc06.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|--------------|----|----------|----------|
| 1 | aceleran | 1 | 2.30259 | 2.30259 |
| 10 | artificial | 1 | 2.30259 | 2.30259 |
| 17 | cambio | 1 | 2.30259 | 2.30259 |
| 40 | el | 1 | 0.356675 | 0.356675 |
| 51 | gicas | 1 | 2.30259 | 2.30259 |
| 54 | industrias | 1 | 2.30259 | 2.30259 |
| 55 | innovaciones | 1 | 2.30259 | 2.30259 |
| 56 | inteligencia | 1 | 2.30259 | 2.30259 |
| 59 | las | 1 | 1.60944 | 1.60944 |
| 103 | rob | 1 | 2.30259 | 2.30259 |
| 113 | tecnol | 1 | 2.30259 | 2.30259 |
| 115 | tica | 1 | 2.30259 | 2.30259 |
| 116 | transforman | 1 | 2.30259 | 2.30259 |
| 121 | y | 1 | 0.105361 | 0.105361 |

Documento: /workspaces/modelos_basados_contenido/samples/new_docs/doc07.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|-----------|----|----------|----------|
| 18 | carretera | 1 | 2.30259 | 2.30259 |
| 25 | comida | 1 | 2.30259 | 2.30259 |
| 34 | del | 1 | 1.60944 | 1.60944 |
| 37 | disfrut | 1 | 2.30259 | 2.30259 |
| 40 | el | 1 | 0.356675 | 0.356675 |
| 46 | familia | 1 | 2.30259 | 2.30259 |
| 58 | la | 2 | 0.356675 | 0.71335 |
| 62 | local | 1 | 1.20397 | 1.20397 |
| 71 | monta | 1 | 2.30259 | 2.30259 |
| 72 | mostr | 1 | 2.30259 | 2.30259 |
| 82 | os | 1 | 1.60944 | 1.60944 |
| 83 | osos | 1 | 2.30259 | 2.30259 |
| 86 | paisaje | 1 | 2.30259 | 2.30259 |
| 87 | paisajes | 1 | 2.30259 | 2.30259 |

| | | | | |
|-----|-------|---|----------|----------|
| 95 | por | 1 | 2.30259 | 2.30259 |
| 99 | r | 1 | 2.30259 | 2.30259 |
| 120 | viaje | 1 | 2.30259 | 2.30259 |
| 121 | y | 2 | 0.105361 | 0.210721 |

Documento: /workspaces/modelos_basados_contenido/samples/new_docs/doc08.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|-------------|----|----------|-----------------|
| 8 | aplaudieron | | 1 | 2.30259 2.30259 |
| 14 | blico | 1 | 2.30259 | 2.30259 |
| 21 | cl | 1 | 2.30259 | 2.30259 |
| 27 | con | 1 | 1.60944 | 1.60944 |
| 28 | concierto | 1 | 2.30259 | 2.30259 |
| 29 | contempor | 1 | 2.30259 | 2.30259 |
| 35 | director | 1 | 2.30259 | 2.30259 |
| 36 | dirigi | 1 | 2.30259 | 2.30259 |
| 40 | el | 3 | 0.356675 | 1.07002 |
| 63 | los | 1 | 0.916291 | 0.916291 |
| 65 | m | 2 | 2.30259 | 4.60517 |
| 74 | n | 1 | 1.20397 | 1.20397 |
| 75 | nea | 1 | 2.30259 | 2.30259 |
| 81 | ofreci | 1 | 2.30259 | 2.30259 |
| 84 | p | 1 | 1.60944 | 1.60944 |
| 90 | pasi | 1 | 2.30259 | 2.30259 |
| 106 | sica | 2 | 1.60944 | 3.21888 |
| 107 | sicos | 1 | 2.30259 | 2.30259 |
| 121 | y | 2 | 0.105361 | 0.210721 |

Documento: /workspaces/modelos_basados_contenido/samples/new_docs/doc09.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|--------------|----|----------|-----------------|
| 2 | actividad | | 1 | 2.30259 2.30259 |
| 12 | bienestar | | 1 | 2.30259 2.30259 |
| 13 | blica | 1 | 2.30259 | 2.30259 |
| 26 | comunitarios | 1 | 2.30259 | 2.30259 |
| 40 | el | 1 | 0.356675 | 0.356675 |
| 45 | f | 1 | 1.60944 | 1.60944 |
| 48 | fomentan | 1 | 2.30259 | 2.30259 |
| 58 | la | 3 | 0.356675 | 1.07002 |
| 74 | n | 1 | 1.20397 | 1.20397 |
| 84 | p | 1 | 1.60944 | 1.60944 |
| 96 | prevenci | 1 | 2.30259 | 2.30259 |
| 97 | programas | 1 | 2.30259 | 2.30259 |
| 98 | promueve | 1 | 2.30259 | 2.30259 |
| 104 | salud | 1 | 2.30259 | 2.30259 |
| 106 | sica | 1 | 1.60944 | 1.60944 |
| 121 | y | 1 | 0.105361 | 0.105361 |

Documento: /workspaces/modelos_basados_contenido/samples/new_docs/doc10.txt

| Idx | Termino | TF | IDF | TF-IDF |
|-----|------------|----|----------|-----------------|
| 9 | arte | 1 | 2.30259 | 2.30259 |
| 11 | artistas | | 1 | 2.30259 2.30259 |
| 23 | cnicas | 1 | 2.30259 | 2.30259 |
| 33 | de | 1 | 1.20397 | 1.20397 |
| 40 | el | 1 | 0.356675 | 0.356675 |
| 42 | esculturas | 1 | 2.30259 | 2.30259 |
| 43 | estilos | 1 | 2.30259 | 2.30259 |
| 44 | exhibe | 1 | 2.30259 | 2.30259 |
| 62 | local | 1 | 1.20397 | 1.20397 |
| 63 | los | 1 | 0.916291 | 0.916291 |
| 68 | mercado | 1 | 2.30259 | 2.30259 |
| 73 | muestran | 1 | 2.30259 | 2.30259 |
| 80 | nuevas | 1 | 2.30259 | 2.30259 |
| 93 | pinturas | 1 | 2.30259 | 2.30259 |
| 111 | t | 1 | 2.30259 | 2.30259 |
| 121 | y | 2 | 0.105361 | 0.210721 |

Matriz de similitud coseno:

| | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 |
|-----------|---|------------|-----------|------------|---|-------------|---|------------|---|-------------|
| 0 | 1 | 0.00568828 | | 0.00480499 | | 0.149924 | | 0.00560604 | | 0.00204049 |
| 0.0124914 | | 0.00468916 | | 0.0193855 | | 0.00218322 | | | | |
| 1 | | 0.00568828 | 1 | 0.00184468 | | | | 0.00215221 | | 0.000178517 |
| 0.0643976 | | | 0.0109079 | 0.00646763 | | 0.0368151 | | | | |
| 2 | | 0.00480499 | | 0.00184468 | 1 | 0.00159703 | | 0.00181801 | | 0.0705251 |
| 0.03613 | | 0.0157357 | | 0.0256271 | | 0.000298716 | | | | |

| | | | | | | |
|------------|------------|-------------|-------------|------------|-------------|-------------|
| 3 | 0.149924 | 0.0143679 | 0.00159703 | 1 | 0.0230939 | 0.00385145 |
| 0.00714611 | 0.0499583 | 0.050011 | 0.0381355 | | | |
| 4 | 0.00560604 | 0.00215221 | 0.00181801 | 0.0230939 | 1 | 0.000175936 |
| 0.00406746 | 0.00027695 | 0.00637412 | 0.0231032 | | | |
| 5 | 0.00204049 | 0.000178517 | 0.0705251 | 0.00385145 | 0.000175936 | 1 |
| 0.00227059 | 0.00520663 | 0.00232005 | 0.00242415 | | | |
| 6 | 0.0124914 | 0.0643976 | 0.03613 | 0.00714611 | 0.00406746 | 0.00227059 |
| 0.00509582 | 0.0142028 | 0.0244005 | | | | |
| 7 | 0.00468916 | 0.0109079 | 0.0157357 | 0.0499583 | 0.00027695 | 0.00520663 |
| 0.00509582 | 1 | 0.127058 | 0.0161615 | | | |
| 8 | 0.0193855 | 0.00646763 | 0.0256271 | 0.050011 | 0.00637412 | 0.00232005 |
| 0.0142028 | 0.127058 | 1 | 0.00248234 | | | |
| 9 | 0.00218322 | 0.0368151 | 0.000298716 | 0.0381355 | 0.0231032 | 0.00242415 |
| 0.0244005 | 0.0161615 | 0.00248234 | 1 | | | |